

# **Intro to Machine Learning: Assignment #4**

May 12, 2023

**Dor Bourshan**

315780122

# Theory Questions

## 1 SVM with multiple classes.

יהיו  $\mathbf{x}_1, \dots, \mathbf{x}_n \in \mathbb{R}^d$  ויהיו  $y_1, \dots, y_n \in [K]$  labels מתוך קבוצה בת  $K$  labels.

נמצא מפריד לכל אחד מהמחלקות  $j \in [K]$ .

נגדיר את פונקציית loss הבאה (multiclass hinge – loss):

$$\ell(\mathbf{w}_1, \dots, \mathbf{w}_K, \mathbf{x}_i, y_i) = \max_{j \in [K]} (\langle \mathbf{w}_j, \mathbf{x}_i \rangle - \langle \mathbf{w}_{y_i}, \mathbf{x}_i \rangle + 1 \mathbf{1}(j \neq y_i))$$

נגדיר את בעיית ה multiclass SVM:

$$f(\mathbf{w}_1, \dots, \mathbf{w}_K) = \frac{1}{n} \sum_{i=1}^n \ell(\mathbf{w}_1, \dots, \mathbf{w}_K, \mathbf{x}_i, y_i)$$

אחרי תהליך הלמידה אנחנו נסווג נקודות באופן הבא  $\arg \max_{j \in [K]} \langle \mathbf{w}_j, \mathbf{x}_i \rangle$ . נאמר כי אנחנו במקרה בו ה data מופרד. כלומר, קיימים  $\mathbf{w}_1^*, \dots, \mathbf{w}_K^*$  כך ש  $\langle \mathbf{w}_y^*, \mathbf{x}_i \rangle > \langle \mathbf{w}_{y'}^*, \mathbf{x}_i \rangle$  לכל  $y \in [K]$  ו  $y' \neq y$ . נראה שכל  $\mathbf{w}_1, \dots, \mathbf{w}_K$  שממנמים את  $f(\mathbf{w}_1, \dots, \mathbf{w}_K)$  משיגים שגיאה אפס על הקלספיקציה.

אם כן, אנו נדרשים לבצע

$$\min_{\mathbf{w}_1, \dots, \mathbf{w}_K} f(\mathbf{w}_1, \dots, \mathbf{w}_K)$$

תחילה נפשט את הפונקציה להצגה אינפורמטיבית:

$$\begin{aligned} f(\mathbf{w}_1, \dots, \mathbf{w}_K) &= \frac{1}{n} \sum_{i=1}^n \ell(\mathbf{w}_1, \dots, \mathbf{w}_K, \mathbf{x}_i, y_i) = \frac{1}{n} \sum_{i=1}^n \max_{j \in [K]} (\langle \mathbf{w}_j, \mathbf{x}_i \rangle - \langle \mathbf{w}_{y_i}, \mathbf{x}_i \rangle + 1 \mathbf{1}(j \neq y_i)) \\ &= \frac{1}{n} \sum_{i=1}^n \max \left\{ \max_{\substack{j \in [K] \\ j \neq y_i}} (\langle \mathbf{w}_j, \mathbf{x}_i \rangle - \langle \mathbf{w}_{y_i}, \mathbf{x}_i \rangle + 1), 0 \right\} \end{aligned}$$

כעת אנו יכולים לראות כי

$$f(\mathbf{w}_1, \dots, \mathbf{w}_K) \geq 0 \quad (1)$$

נראה כי

$$\ell(\mathbf{w}_1, \dots, \mathbf{w}_K, \mathbf{x}_i, y_i) \geq \ell_{1-0}(h(\mathbf{x}_i), y_i)$$

כלומר אנו נדרשים להראות כי:

$$\max_{j \in [K]} (\langle \mathbf{w}_j, \mathbf{x}_i \rangle - \langle \mathbf{w}_{y_i}, \mathbf{x}_i \rangle + 1 \mathbf{1}(j \neq y_i)) \geq 1 \mathbf{1}(\arg \max_{j \in [K]} \langle \mathbf{w}_j, \mathbf{x}_i \rangle \neq y_i)$$

נפריד למקרים:

• עבור  $\arg \max_{j \in [K]} \langle \mathbf{w}_j, \mathbf{x}_i \rangle = y_i$  אנו נקבל כי

$$\max_{j \in [K]} (\langle \mathbf{w}_j, \mathbf{x}_i \rangle - \langle \mathbf{w}_{y_i}, \mathbf{x}_i \rangle + 1 (j \neq y_i)) \stackrel{1}{\geq} 0$$

• אם  $\arg \max_{j \in [K]} \langle \mathbf{w}_j, \mathbf{x}_i \rangle \neq y_i$  מתקיים כי קיים  $j \neq y_i$  כך ש  $\arg \max_{j \in [K]} \langle \mathbf{w}_j, \mathbf{x}_i \rangle = j$  כלומר

$$\begin{aligned} \langle \mathbf{w}_j, \mathbf{x}_i \rangle &\geq \langle \mathbf{w}_{y_i}, \mathbf{x}_i \rangle \implies \langle \mathbf{w}_j, \mathbf{x}_i \rangle - \langle \mathbf{w}_{y_i}, \mathbf{x}_i \rangle \geq 0 \implies \langle \mathbf{w}_j, \mathbf{x}_i \rangle - \langle \mathbf{w}_{y_i}, \mathbf{x}_i \rangle + 1 \geq 1 \\ &\implies \max_{j \in [K]} (\langle \mathbf{w}_j, \mathbf{x}_i \rangle - \langle \mathbf{w}_{y_i}, \mathbf{x}_i \rangle + 1 (j \neq y_i)) \geq 1 \\ &\implies \max_{j \in [K]} (\langle \mathbf{w}_j, \mathbf{x}_i \rangle - \langle \mathbf{w}_{y_i}, \mathbf{x}_i \rangle + 1 (j \neq y_i)) \geq 1 \left( \arg \max_{j \in [K]} \langle \mathbf{w}_j, \mathbf{x}_i \rangle \neq y_i \right) \end{aligned}$$

כלומר הראנו כי

$$\ell(\mathbf{w}_1, \dots, \mathbf{w}_K, \mathbf{x}_i, y_i) \geq \ell_{1-0}(h(\mathbf{x}_i), y_i) \quad (2)$$

נראה כי קיימים  $\mathbf{w}_1^*, \dots, \mathbf{w}_K^*$  כך ש  $f(\mathbf{w}_1^*, \dots, \mathbf{w}_K^*) = 0$  ונקבל מ **1** כי ה"ל מנמנים את  $f$ .

נזכור כי ה data מופרד. כלומר, קיימים  $\mathbf{w}_1^*, \dots, \mathbf{w}_K^*$  כך ש  $y_i = \arg \max_y \langle \mathbf{w}_y^*, \mathbf{x}_i \rangle$  לכל  $i$ .

נסמן

$$\max_{1 \leq i \leq n} \max_{\substack{j \in [K] \\ j \neq y_i}} (\langle \mathbf{w}_j^*, \mathbf{x}_i \rangle - \langle \mathbf{w}_{y_i}^*, \mathbf{x}_i \rangle) = M$$

ונשים לב כי  $M$  מספר שלילי שכן ה data מופרד וכן  $y_i = \arg \max_y \langle \mathbf{w}_y^*, \mathbf{x}_i \rangle$ . נסמן  $\mathbf{w}_i^{**} = -\frac{1}{M} \mathbf{w}_i^*$ . מתקיים כי:

$$\max_{\substack{j \in [K] \\ j \neq y_i}} (\langle \mathbf{w}_j^{**}, \mathbf{x}_i \rangle - \langle \mathbf{w}_{y_i}^{**}, \mathbf{x}_i \rangle) \leq -\frac{1}{M} M = -1$$

לפיכך

$$\max_{\substack{j \in [K] \\ j \neq y_i}} (\langle \mathbf{w}_j^{**}, \mathbf{x}_i \rangle - \langle \mathbf{w}_{y_i}^{**}, \mathbf{x}_i \rangle) + 1 \leq 0$$

ולכן

$$\max \left\{ \max_{\substack{j \in [K] \\ j \neq y_i}} (\langle \mathbf{w}_j^{**}, \mathbf{x}_i \rangle - \langle \mathbf{w}_{y_i}^{**}, \mathbf{x}_i \rangle + 1), 0 \right\} = 0$$

כלומר

$$f(\mathbf{w}_1^{**}, \dots, \mathbf{w}_K^{**}) = \frac{1}{n} \sum_{i=1}^n \max \left\{ \max_{\substack{j \in [K] \\ j \neq y_i}} (\langle \mathbf{w}_j^{**}, \mathbf{x}_i \rangle - \langle \mathbf{w}_{y_i}^{**}, \mathbf{x}_i \rangle + 1), 0 \right\} = \frac{1}{n} \sum_{i=1}^n 0 = 0$$

כלומר הראנו כי מנמום הפונקציה, משמעו כי קיימים  $\mathbf{w}_1, \dots, \mathbf{w}_K$  כך ש  $f(\mathbf{w}_1, \dots, \mathbf{w}_K) = 0$

אם כן יהיו  $\mathbf{w}_1, \dots, \mathbf{w}_K$  כך ש  $f(\mathbf{w}_1, \dots, \mathbf{w}_K) = 0$  מתקבל כי :

$$0 = f(\mathbf{w}_1, \dots, \mathbf{w}_K) = \frac{1}{n} \sum_{i=1}^n \ell(\mathbf{w}_1, \dots, \mathbf{w}_K, \mathbf{x}_i, y_i) \stackrel{2}{\geq} \frac{1}{n} \sum_{i=1}^n \ell_{1-0}(h(\mathbf{x}_i), y_i) \geq 0$$

לפיכך

$$\frac{1}{n} \sum_{i=1}^n \ell_{1-0}(h(\mathbf{x}_i), y_i) = 0$$

כנדרש.

□

## 2 Expressivity of ReLU networks.

מגדירים את ReLU פונקציה אקטיבציה, באופן הבא :

$$h(x) = x^+ = \max\{0, x\}$$

נראה כי ניתן לממש את הפונקציה  $f(x_1, x_2) = \max\{x_1, x_2\}$  באמצעות one hidden layer המורכבת מפונקציית האקטיבציה ReLU. ניתן להניח כי אין פונקציית אקטיבציה לאחר השכבה האחרונה.

אם כן




Figure 1: neural network

כאשר נגדיר :

$$\begin{aligned} a_1^{(1)} &= \frac{x_1 + x_2}{2} \\ a_2^{(1)} &= \frac{x_1 - x_2}{2} \\ a_3^{(1)} &= \frac{-x_1 + x_2}{2} \\ a_4^{(1)} &= \frac{-x_1 - x_2}{2} \end{aligned}$$

וכן

$$\begin{aligned} z_1^{(1)} &= \max\left\{\frac{x_1 + x_2}{2}, 0\right\} \\ z_2^{(1)} &= \max\left\{\frac{x_1 - x_2}{2}, 0\right\} \\ z_3^{(1)} &= \max\left\{\frac{-x_1 + x_2}{2}, 0\right\} \\ z_4^{(1)} &= \max\left\{\frac{-x_1 - x_2}{2}, 0\right\} \end{aligned}$$

וכן

$$a_1^{(2)} = \sum_{i=1}^4 z_i^{(1)}$$

נראה עבור חלוקה למקרה אחד, שאר המקרים דומים באופיים.

1. מתקיים כי  $x_1, x_2 \geq 0$

ולכן מתקיים כי  $z_1^{(1)} = \frac{x_1+x_2}{2}$  וכן  $z_4^{(1)} = 0$

(א) מתקיים כי  $x_1 \geq x_2$

מתקיים כי  $z_3^{(1)} = 0$  וכן  $z_2^{(1)} = \frac{x_1-x_2}{2}$  כמו כן  $z_2^{(1)} = \frac{x_1-x_2}{2} = \frac{|x_1-x_2|}{2}$

(ב) מתקיים כי  $x_1 < x_2$

מתקיים כי  $z_2^{(1)} = 0$  וכן  $z_3^{(1)} = \frac{-x_1+x_2}{2}$  כמו כן  $z_3^{(1)} = \frac{-x_1+x_2}{2} = \frac{|x_1-x_2|}{2}$

ניתן לראות אם כן כי

$$a_1^{(2)} = \sum_{i=1}^4 z_i^{(1)} = \frac{x_1+x_2}{2} + \frac{|x_1-x_2|}{2} = \max\{x_1, x_2\} = f(x_1, x_2)$$

□

### 3 Soft SVM with $\ell^2$ penalty.

נניח שקיימת הבעיה הבאה :

$$\begin{aligned} \min_{\mathbf{w} \in \mathbb{R}^d, b \in \mathbb{R}, \xi \in \mathbb{R}^n} \quad & \frac{1}{2} \|\mathbf{w}\|_2^2 + \frac{C}{2} \sum_{i=1}^n \xi_i^2 \\ \text{s.t.} \quad & y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) \geq 1 - \xi_i \quad \forall i = 1, \dots, n \end{aligned}$$

#### 3.1 section (a)

נראה תחילה כי אם נוסף את האילוץ  $\xi_i \geq 0$  לא נשנה את הפיתרון המינימלי.

אם כן תהיי  $I \subseteq [n]$  קבוצת אינדקסים כך שלכל  $i \in I$  מתקיים

$$\xi_i < 0$$

יהיי  $\mathbf{w} \in \mathbb{R}^d, b \in \mathbb{R}, \xi \in \mathbb{R}^n$  פתרון אופטימלי. מתקיים אם כן כי

$$\begin{aligned} y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) &\geq 1 - \xi_i \geq 1 + \xi_i \quad \forall i \in I \\ y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) &\geq 1 - \xi_i \quad \forall i \in [n] \setminus I \end{aligned}$$

נשים לב כי בפונקציה המנומנמת, אין חשיבות לסימן של  $\xi_i$  ולכן עבור  $i \in I$  אם נחליף את  $\xi_i$  ב  $-\xi_i$  נקבל שהאילוץ מתקיימים וכן ערך הפונקציה המנומנמת זהה.

כלומר נוכל לעבור לבעיה הבאה :

$$\begin{aligned} \min_{\mathbf{w} \in \mathbb{R}^d, b \in \mathbb{R}, \xi \in \mathbb{R}^n} \quad & \frac{1}{2} \|\mathbf{w}\|_2^2 + \frac{C}{2} \sum_{i=1}^n \xi_i^2 \\ \text{s.t.} \quad & y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) \geq 1 - \xi_i \quad \forall i = 1, \dots, n \\ & \xi_i \geq 0 \quad \forall i = 1, \dots, n \end{aligned}$$

□

#### 3.2 section (b)

נרשום את פונקציית הלגרנג'יאן של הבעיה :

$$\begin{aligned} \min_{\mathbf{w} \in \mathbb{R}^d, b \in \mathbb{R}, \xi \in \mathbb{R}^n} \quad & \frac{1}{2} \|\mathbf{w}\|_2^2 + \frac{C}{2} \sum_{i=1}^n \xi_i^2 \\ \text{s.t.} \quad & 0 \geq 1 - \xi_i - y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b) \quad \forall i = 1, \dots, n \\ & 0 \geq -\xi_i \quad \forall i = 1, \dots, n \end{aligned}$$

אם כן

$$\mathcal{L}(\mathbf{w}, b, \xi, \alpha, \beta) = \frac{1}{2} \|\mathbf{w}\|_2^2 + \frac{C}{2} \sum_{i=1}^n \xi_i^2 + \sum_{i=1}^n \alpha_i (1 - \xi_i - y_i (\langle \mathbf{w}, \mathbf{x}_i \rangle + b)) + \sum_{i=1}^n \beta_i (-\xi_i)$$

כאשר אין בבעיה אילוצי שוויון.

□

### 3.3 section (c)

נמנמם את הפונקציה ביחס ל  $\mathbf{w}, b, \xi$ . זוהי תהיה הפונקציה הדואלית.

כלומר

$$g(\alpha, \beta) = \min_{\mathbf{w} \in \mathbb{R}^d, b \in \mathbb{R}, \xi \in \mathbb{R}^n} \mathcal{L}(\mathbf{w}, b, \xi, \alpha, \beta)$$

היא הפונקציה הדואלית.

ראשית נסדר את הלגרנגיאן.

$$\mathcal{L}(\mathbf{w}, b, \xi, \alpha, \beta) = \frac{1}{2} \|\mathbf{w}\|_2^2 - \sum_{i=1}^n \alpha_i y_i \langle \mathbf{w}, \mathbf{x}_i \rangle + \frac{C}{2} \sum_{i=1}^n \left( \xi_i^2 - \frac{2}{C} \xi_i (\alpha_i + \beta_i) \right) + \sum_{i=1}^n \alpha_i y_i b + \sum_{i=1}^n \alpha_i$$

נשים לב כי אם

$$\sum_{i=1}^n \alpha_i y_i \neq 0$$

אין לבעיה מינימום. כיוון שלכל ערך קטן כרצוננו ניתן לבחור  $b$ .

כעת ניתן לראות כי זו פונקציה של סכומים של פונקציות קמורות, ולכן קמורה (מתרגיל 3). והפונקציה דיפרנציאבילית כסכום של פונקציות דיפרנציאביליות.

אם קיים מינימום הוא נמצא בנקודה בה ההגרדיאנט מתאפס.

$$\nabla_{\mathbf{w}} \mathcal{L} = \mathbf{w} - \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i = 0 \implies \mathbf{w} = \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i$$

$$\frac{\partial \mathcal{L}}{\partial b} = \sum_{i=1}^n \alpha_i y_i = 0$$

$$\frac{\partial \mathcal{L}}{\partial \xi_i} = C \cdot \xi_i - (\alpha_i + \beta_i) = 0 \implies \xi_i = \frac{\alpha_i + \beta_i}{C}$$



נציב ונקבל

$$\begin{aligned}
\mathcal{L}(\mathbf{w}, b, \boldsymbol{\xi}, \boldsymbol{\alpha}, \boldsymbol{\beta}) &= \frac{1}{2} \|\mathbf{w}\|_2^2 - \underbrace{\mathbf{w}^\top \sum_{i=1}^n \alpha_i y_i \mathbf{x}_i}_{\mathbf{w}} + \sum_{i=1}^n \alpha_i - \frac{1}{2C} \sum_{i=1}^n (\alpha_i + \beta_i)^2 + b \sum_{i=1}^n \alpha_i y_i \\
&= -\frac{1}{2} \|\mathbf{w}\|_2^2 - \frac{1}{2C} \sum_{i=1}^n (\alpha_i + \beta_i)^2 + \sum_{i=1}^n \alpha_i \\
&= \boxed{-\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i \mathbf{x}_j - \frac{1}{2C} \sum_{i=1}^n (\alpha_i + \beta_i)^2 + \sum_{i=1}^n \alpha_i}
\end{aligned}$$

### 3.4 section (d)

הפונקציה הדואלית:

$$g(\boldsymbol{\alpha}, \boldsymbol{\beta}) = -\frac{1}{2} \sum_{i=1}^n \sum_{j=1}^n \alpha_i \alpha_j y_i y_j \mathbf{x}_i \mathbf{x}_j - \frac{1}{2C} \sum_{i=1}^n (\alpha_i + \beta_i)^2 + \sum_{i=1}^n \alpha_i$$

הבעיה הדואלית:

$$\begin{aligned}
&\max g(\boldsymbol{\alpha}, \boldsymbol{\beta}) \\
&\sum_{i=1}^n \alpha_i y_i = 0 \\
&\alpha_i, \beta_i \geq 0 \quad \forall i = 1, \dots, n
\end{aligned}$$

□

## 4 Gradient of cross-entropy loss over softmax.

יהי  $\mathbf{y} \in \{0, 1\}^d$  וקטור בעל כניסה אחת של 1 והשאר 0. נגדיר את הפונקציה  $\ell_{\mathbf{y}} : \mathbb{R}^d \rightarrow \mathbb{R}$  הנקראת *cross-entropy loss* ע"י :

$$\ell_{\mathbf{y}}(\mathbf{w}) = -\mathbf{y} \ln(\text{softmax}(\mathbf{w}))$$

כאשר

$$\text{softmax}(\mathbf{w}) = \left( \frac{e^{w_1}}{\sum_{j=1}^d e^{w_j}}, \dots, \frac{e^{w_d}}{\sum_{j=1}^d e^{w_j}} \right)$$

וכן הלוגריתם מודר על וקטור כאיבר איבר.

נחשב את הדרדיאנט של  $\ell_{\mathbf{y}}(\mathbf{w})$  :

$$\begin{aligned} \ell_{\mathbf{y}}(\mathbf{w}) &= -\mathbf{y} \ln(\text{softmax}(\mathbf{w})) = -\sum_{i=1}^n y_i \ln \left( \frac{e^{w_i}}{\sum_{j=1}^d e^{w_j}} \right) = \sum_{i=1}^n \left( -y_i \ln(e^{w_i}) + y_i \ln \left( \sum_{j=1}^d e^{w_j} \right) \right) = \\ &= \sum_{i=1}^n -y_i w_i + \sum_{i=1}^n y_i \ln \left( \sum_{j=1}^d e^{w_j} \right) \end{aligned}$$

נגזור

$$\frac{\partial \ell}{\partial w_q} = -y_q + \sum_{i=1}^n y_i \frac{e^{w_q}}{\sum_{j=1}^d e^{w_j}}$$

נזכור כי יש רק כניסה אחת ל  $\mathbf{y}$  ששווה ל 1 ושאר הכניסות אפסים.

$$\frac{\partial \ell}{\partial w_q} = -y_q + \frac{e^{w_q}}{\sum_{j=1}^d e^{w_j}}$$

ולכן

$$\nabla \ell_{\mathbf{y}}(\mathbf{w}) = \text{softmax}(\mathbf{w}) - \mathbf{y}$$

□

# Programming Assignment